



Filtragem de mediana

Filtragem de ruído

- Vimos que os filtros de média aritmética e ponderada (filtros convolucionais de suavização) permitem reduzir o ruído
 - Todavia o fazem às custas de redução no contraste local (suavização das bordas)
- A média tem efeito de igualar a intensidade de um pixel às de seus vizinhos
 - Com isso diminui o efeito dos *outliers*
 - Porém reduz o contraste nas transições (bordas locais)

Filtragem de ruído

- Uma boa alternativa que consegue preservar bem o contraste é o emprego da mediana da vizinhança, em vez da média
 - A média se coloca no centróide da vizinhança, considerando-se as intensidades como pesos
 - A mediana é o valor que se encontra no centro geométrico da distribuição das intensidades, ordenadas sequencialmente
 - É um valor que mantém certo contraste, pois coloca-se bem no meio da faixa dinâmica da vizinhança

Filtro de mediana

- Algoritmo
- Dada a imagem I e um tamanho de vizinhança (em geral, ímpar)
 - Para cada pixel de I , obter sua vizinhança
 - Ordenar a vizinhança e achar o elemento central (mediana)
 - O valor do pixel na imagem filtrada será o da mediana de sua vizinhança

Exemplo de mediana de uma vizinhança

$$\text{Vizinhança} = \begin{pmatrix} 255 & 243 & 221 \\ 232 & 121 & 120 \\ 242 & 244 & 239 \end{pmatrix}$$

Ordenando a vizinhança, vem:

$$(120 \ 121 \ 221 \ 232 \ 239 \ 242 \ 243 \ 244 \ 255)$$

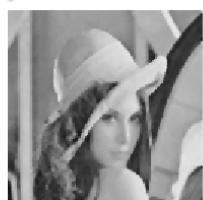
↑
Mediana

Exemplo

- Filtragem de mediana da imagem Lena (normal) com vizinhança de tamanho 3×3



I

 I_{filtr}

Exemplo 2

- Filtragem de mediana da imagem Lena (5% de ruído gaussiano monocromático) com vizinhanças de tamanho 3×3 e 5×5



I

 $I_{mediana3}$  $I_{mediana5}$

Comparação com filtro de média

- vizinhanças de tamanho 3×3



I

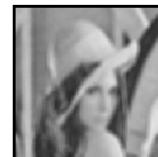
 I_{filtr}  $I_{mediana3}$

Comparação com filtro de média

- vizinhanças de tamanho 5×5



I

 I_{filtr}  $I_{mediana5}$

Teoria da Informação

INFORMAÇÃO

Conceito de Informação

- A informação se define em relação a uma mensagem.
- A mensagem pode ser qualquer coisa, em princípio, enviada por um emissor, com destino a um receptor
 - Por exemplo, uma imagem
- Ao se abstrair os aspectos físicos da mensagem, o que resta é a informação

Conceito de Informação

- Podemos considerar, em princípio, tanto o o emissor quanto o receptor como entidades abstratas
 - Supor que o emissor é o processo capaz de gerar uma imagem
 - Supor que o receptor é o processo capaz de ler uma imagem (carregá-la na memória, p.ex)

Conceito de Informação

- A informação é o “conteúdo” da mensagem
- Não o suporte físico da mesma
- Por exemplo, na frase:
 - A aula já começou !
 - Seu suporte físico são as letras, as palavras, escritas e apresentadas
 - Seu conteúdo é aquilo que elas significam, a idéia de aula, o conceito de começar, o fato de ela já ter ou não começado e a exclamação no final.
 - A questão de se a aula já havia começado ou não quando a mensagem foi recebida, muda o conteúdo de informação da mensagem

Conceito de Informação

- Portanto, o estado do receptor é significativo para se determinar as características da informação
 - Se a aula ainda não tivesse começado no entender dos alunos, a mensagem poderia ter o significado: “Vou começar agora”.
 - Se os alunos entendessem que a aula já havia começado, poderiam interpretar a mensagem como: “Vocês não estão prestando atenção”.

Conceito de Informação

- A informação permite alterar o estado de conhecimento do receptor sobre o emissor



Conceito de Informação

- Quanto mais improvável a mensagem, mais informação ela transporta



Medida da Informação

- Resumindo:
 - Quanto mais provável a mensagem (i.e., seu conteúdo), tanto menor a informação que ela traz
- Com base nesse conceito vamos “construir” uma medida para a informação
- Em seguida, vamos interpretar essa medida assim construída

Medida da informação

- A quantidade de informação em uma mensagem depende inversamente da probabilidade da mensagem
 - Em nosso caso a mensagem é a imagem

Conjunto de todas as mensagens

$$I \sim \frac{1}{P(m)}$$

Medida da informação

- Quando se tem a conjunção de duas mensagens :
 - Do ponto de vista lógico booleano, é uma operação “e” (AND)
 - Do ponto de vista de teoria de conjuntos é uma intersecção
- Exemplo: se você envia a mesma mensagem duas vezes, deve ser entendida como uma só:

$$M \cdot M = M$$

Medida da informação

- Quando se tem a conjunção de duas mensagens :
 - Desejamos que a informação seja **aditiva** nesse caso, i.e., dadas duas mensagens concomitantes, queremos que suas informações se somem
- Porém, nesse caso suas probabilidades se **multiplicam**:

$$P(m1 \cdot m2) = P(m1) \cdot P(m2)$$

↑
Conjunção (AND) ↑
Multiplicação

Medida da informação

- Estabelecemos que a medida da informação deve somar quando as probabilidades se multiplicam
 - A solução funcional para isso é empregar o logaritmo:

$$\begin{aligned} I &\sim \frac{1}{P(m)}, & I(m1 \cdot m2) &= I(m1) + I(m2) \\ &, & P(m1 \cdot m2) &= P(m1) \cdot P(m2) \end{aligned} \quad \left\{ \begin{array}{l} I = \log \left(\frac{1}{P(m)} \right) \\ \text{Conjunção (AND)} \quad \text{Multiplicação} \end{array} \right.$$

Medida da informação

$$\begin{aligned} I &\sim \frac{1}{P(m)}, & I(m1 \cdot m2) &= I(m1) + I(m2) \\ &, & P(m1 \cdot m2) &= P(m1) \cdot P(m2) \end{aligned} \quad \left\{ \begin{array}{l} I = \log \left(\frac{1}{P(m)} \right) \\ \text{Conjunção (AND)} \quad \text{Multiplicação} \end{array} \right.$$

ou $I = -\log P(m)$

portanto $I(m1 \cdot m2) = -\log P(m1 \cdot m2) = -\log [P(m1) \cdot P(m2)] = -\log P(m1) - \log P(m2) = I(m1) + I(m2)$

Medida da Informação

- Interpretemos agora a medida da informação que acabamos de construir seguindo um procedimento heurístico

$$I = - \log P(m)$$

- Primeiramente, vamos nos ater a um caso limite, em que as mensagens são simples e equiprováveis

Medida da Informação

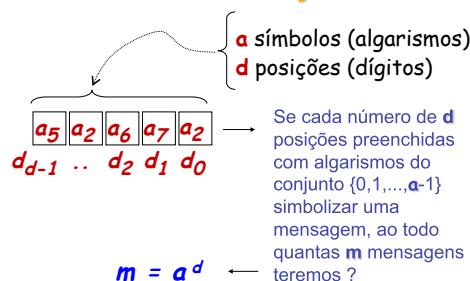
- Suponhamos que todas as mensagens sejam equiprováveis. Vamos ordená-las em ordem lexicográfica e atribuir a cada uma delas um número.

COMBINEMOS OS CÓDIGOS DAS SMS'S:
MENSAGEM 1 - AR-CONDICIONADO QUÊBRADO
MENSAGEM 2 - BANCO DE DADOS FORA DO AR
MENSAGEM 3 - COMPUTADORES SEM REDE
MENSAGEM 4 - ... NÃO ENTENDI ...
ENTENDEU ?



Se tivermos ao todo 10 diferentes mensagens e usarmos 10 números para representá-las, quantos dígitos serão necessários ?

Medida da Informação



Medida da Informação

- O resultado significa que com **a** símbolos e **d** dígitos pode-se representar $m = a^d$ mensagens.
- Inversamente: sabendo-se que temos **m** mensagens e **a** símbolos, quantos dígitos **d** são necessários para representar essas mensagens ?
– Resposta: $d = \log_a m$

Medida da Informação

- Exemplo:
 - Se **a** = 2 algarismos temos: símbolos = {0,1} → conjunto binário (apenas 2 símbolos)
 - Quantos dígitos binários (i.e., bits) serão necessários para representar **m** mensagens ?

$$d = \log_2 m$$

- Portanto se usarmos log na base 2, a resposta será dada em bits.

Medida da Informação

- Suponhamos que as **m** mensagens sejam equiprováveis. Então, qual a probabilidade de cada mensagem m_i ?

$$P(m_i) = \frac{1}{m}$$

- Logo:

$$m = \frac{1}{P(m_i)}$$

Medida da Informação

Portanto, uma mensagem m_i de um conjunto de m mensagens equiprováveis pode ser representada com a símbolos requerendo d dígitos:

$$m = \frac{1}{P(m_i)}, \quad d = \log_a m \rightarrow d = \log_a \frac{1}{P(m_i)}$$

Então, a medida da informação da mensagem m_i de probabilidade $P(m_i)$ pode ser interpretada como o comprimento em dígitos requerido para representar a mensagem com a símbolos

$$I_i = -\log_a P(m_i)$$

Entropia

- Define-se a **entropia** de um conjunto de símbolos (mensagem) como a **informação média** dos símbolos presentes na mensagem.
- Por ser informação média, a entropia mede a quantidade média de dígitos por símbolo, requeridos para representar a mensagem.

Entropia

- Para cada símbolo m_i :

$$I_i = -\log_a P(m_i)$$

- Logo, para uma mensagem com n símbolos:

$$H = \langle I \rangle = - \sum_{i=0}^{n-1} \log_a P(m_i) \cdot P(m_i)$$

Entropia de uma imagem

- Uma imagem pode ser considerada como uma mensagem composta de $n = L \times C$ símbolos, os pixels, sendo L a quantia de linhas e C a de colunas.
- Sendo a imagem digital, a **quantidade média de bits** requeridos para representar os **pixels** da imagem será dada por sua entropia:

$$H = - \sum_{i,j} \log_2 p(I_{ij}) \cdot p(I_{ij})$$

Entropia de uma imagem

- As probabilidades dos valores dos pixels I_{ij} pode ser obtida do histograma da imagem.
- O **histograma de frequências relativas** h_v ($v = 0, \dots, 255$) é o estimador da densidade de probabilidade dos pixels na imagem

$$H = - \sum_{i,j} \log_2 p(I_{ij}) \cdot p(I_{ij})$$

ou

$$H = - \sum_v \log_2 (h_v) \cdot h_v$$

Entropia de uma imagem

• Advertência:

- A forma correta de se denominar a grandeza abaixo é: entropia dos tons monocromáticos da imagem, ou intensidades (*grey-level entropy*)

$$H = - \sum_{i,j} \log_2 p(I_{ij}) \cdot p(I_{ij})$$

ou

$$H = - \sum_v \log_2 (h_v) \cdot h_v$$

- Para se definir uma entropia para as imagens em si, seria necessário conhecer mais sobre as correlações entre os pixels, sobre a estrutura espacial da imagem, sobre o processo estocástico que produz as imagens

Exemplos

- Vamos calcular as entropias das intensidades de algumas imagens.
 - As imagens abaixo diferem na quantidade de bits usados para representá-las. Descobrir quais as quantidades de cada uma:



Raphael A



Raphael B

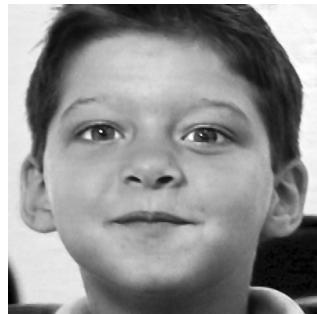


Raphael C



Raphael D

Raphael A



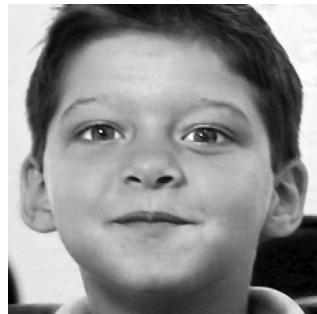
Entropia
6,888 bits

Raphael B



Entropia
5,835 bits

Raphael C



Entropia
7,782 bits

Raphael D



Entropia
4,839 bits

Observação

- As imagens mostradas não são de fato as que foram utilizadas nos cálculos. Elas foram equalizadas para poderem ser vistas:



Raphael A



Raphael B



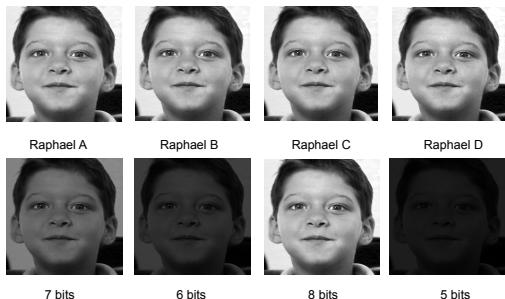
Raphael C



Raphael D

- Vejam como são as imagens reais:

Observação

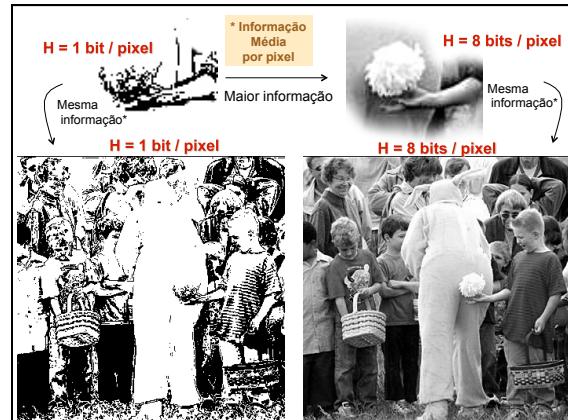


Teorema

- A função H tem valor máximo no, e unicamente no, ponto onde a probabilidade de cada evento é igual a $1/n$
 - Dem: A demonstração, a ser feita na lousa, baseia-se na técnica dos multiplicadores de Lagrange.

Exercício

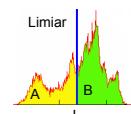
- Explicar porquê as imagens ficaram mais escuras ao se diminuir a quantidade de bits usada para representá-las
- Construir uma transformação de LUT para produzir a partir de uma imagem de 8 bits as imagens com tons de cinza que correspondam a 7,6,5,4,3,2 e 1 bit.
- Obter os histogramas dessas imagens.
- Calcular as entropias dessas imagens.

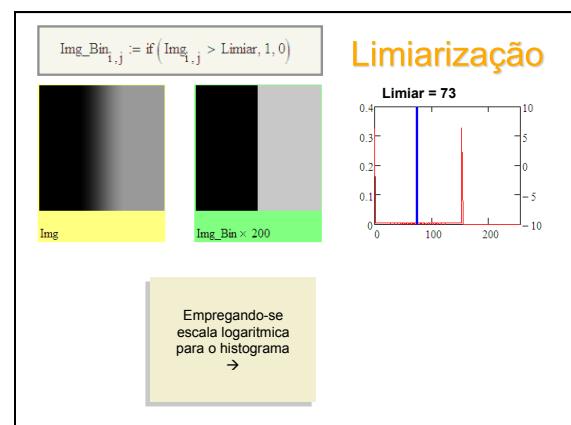
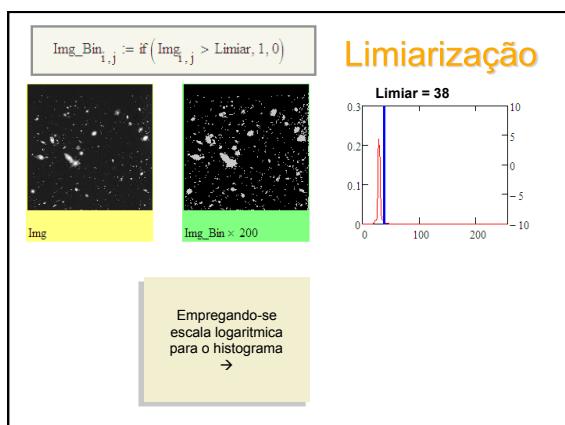
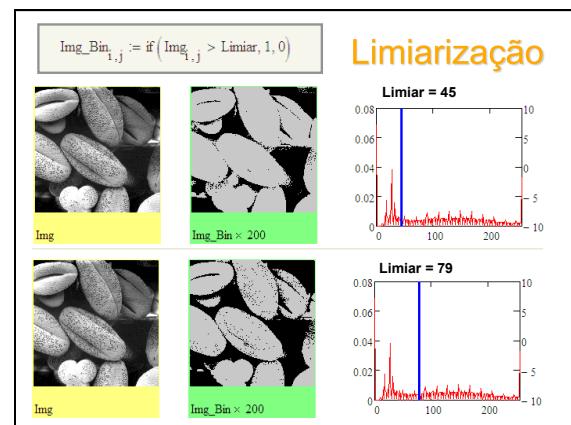
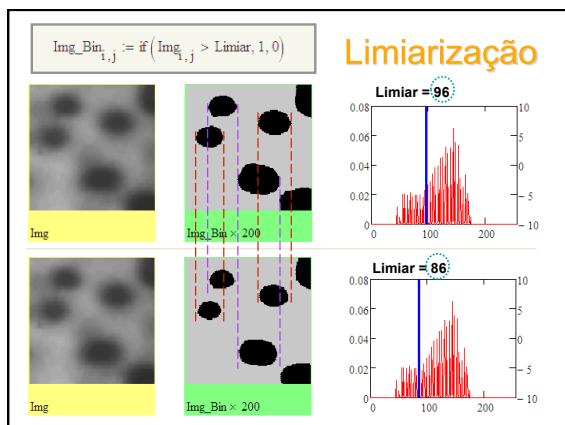
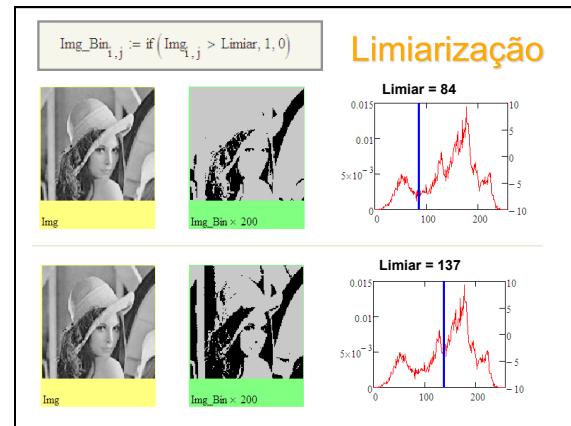
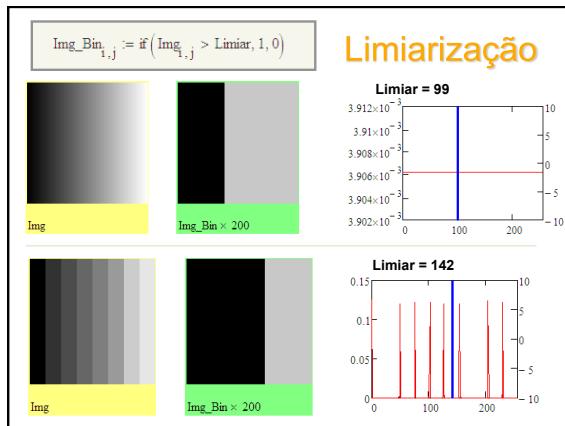


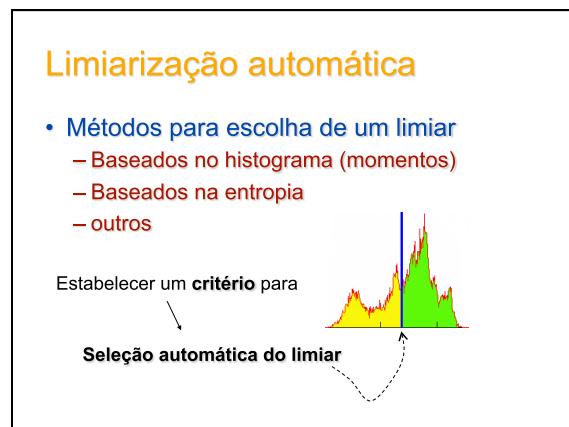
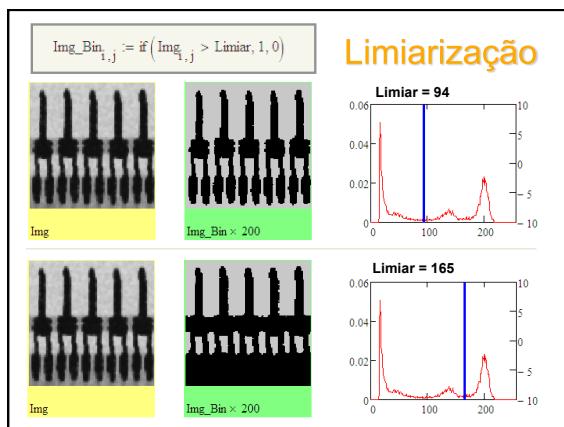
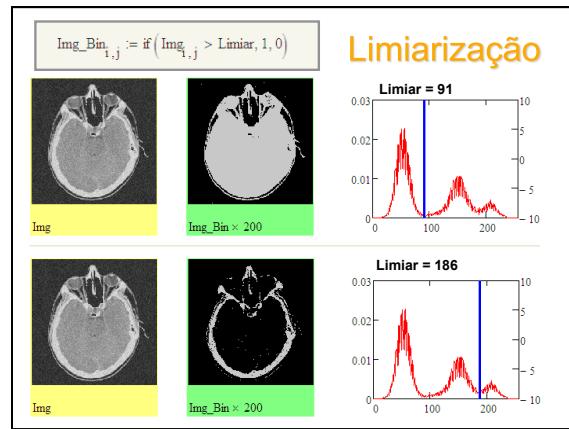
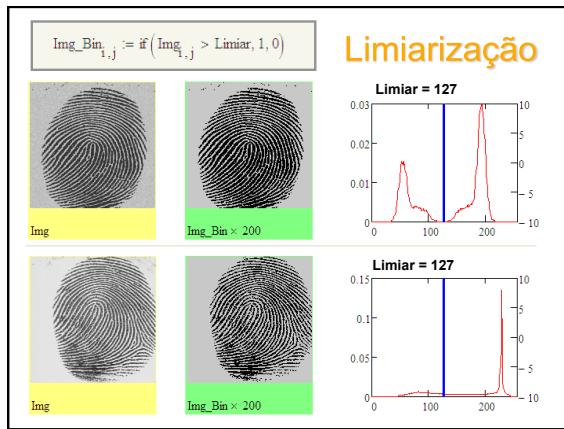
Limiarização (Thresholding)

Limiarização

- Limiar (threshold) → valor limite L para tomar uma decisão
 - $X \leq L \rightarrow$ decisão A
 - $X > L \rightarrow$ decisão B
- No caso de limiarização da intensidade, ou limiarização de níveis de cinza (*grey-level thresholding*):
 - X = intensidade ou nível de cinza
 - Decisão → classificar o nível X como pertencente à classe A ou B
 - A limiarização partitiona o histograma em 2 distribuições que correspondem a duas classes
 - A limiarização é um caso particular de classificação de regiões
 - Classificação binária com critério global baseado no histograma







Limiarização – método de Otsu (1978)

- Também chamado de limiarização por maximização da variância inter-classes
- Baseado no histograma
- Supõe a mistura de duas distribuições formando o histograma total
- O objetivo é encontrar o limiar que separa essas distribuições
- A técnica usada é análise discriminante linear

Limiarização – método de Otsu (1978)

$$\omega_A(L) = \sum_{v=0}^L h_v \quad \text{probabilidade da classe A}$$

$$\omega_B(L) = 1 - \omega_A(L) \quad \text{probabilidade da classe B}$$

$$\mu_L(L) := \sum_{v=0}^L (v \cdot h_v) \quad \text{média até o limiar L}$$

$$\mu_T := \frac{1}{N} \sum_{v=0}^{255} (v \cdot h_v) \quad \text{média da imagem}$$

$$\mu_A(L) := \frac{\mu_T}{\omega_A(L)} \quad \text{média da classe A}$$

$$\mu_B(L) := \frac{\mu_T - \mu_L(L)}{\omega_B(L)} \quad \text{média da classe B}$$

$$\sigma_{AB}^2 = \omega_A (\mu_A - \mu_T)^2 + \omega_B (\mu_B - \mu_T)^2 \quad \text{variância inter-classes}$$

Limiarização – método de Otsu (1978)

variância inter-classes

$$\sigma_{AB}^2 = \omega_A (\mu_A - \mu_T)^2 + \omega_B (\mu_B - \mu_T)^2$$

variância total

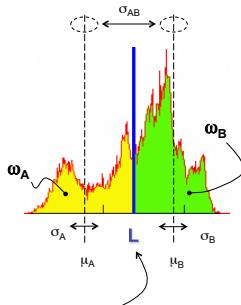
$$\sigma_T^2 = \sum_{v=0}^{255} [v - \mu_T]^2 \cdot h_v$$

função critério a ser maximizada

$$D = \frac{\sigma_{AB}^2}{\sigma_T^2}$$

limiar ótimo

$$L_{opt} = \operatorname{ArgMax}_{0 < L < 255} (D)$$

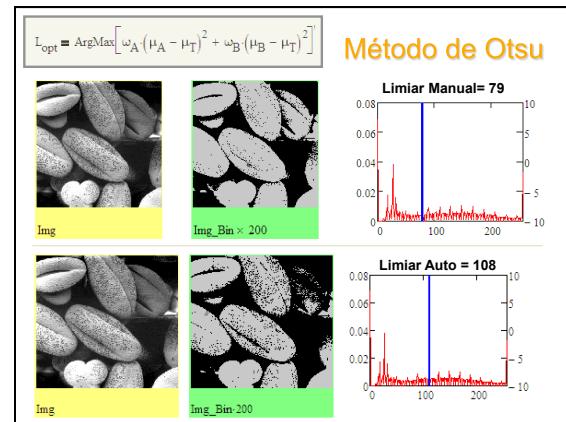
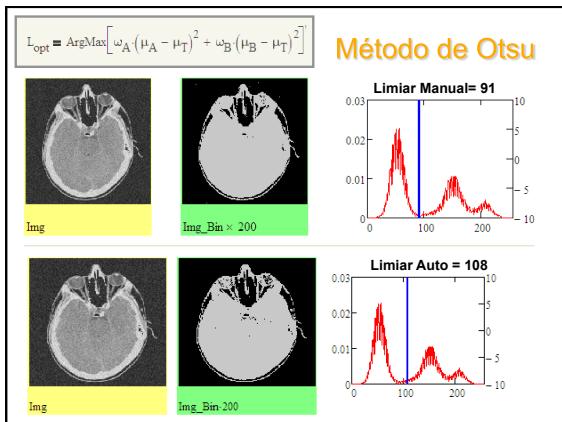
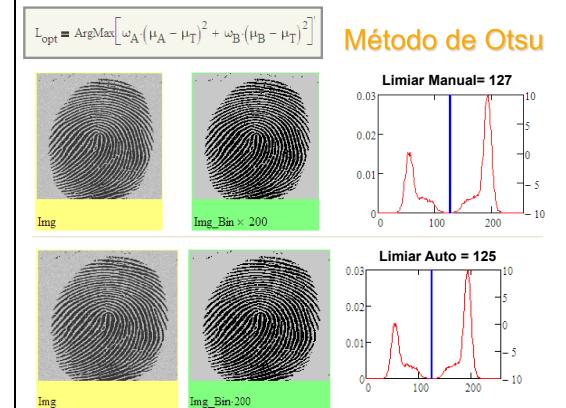
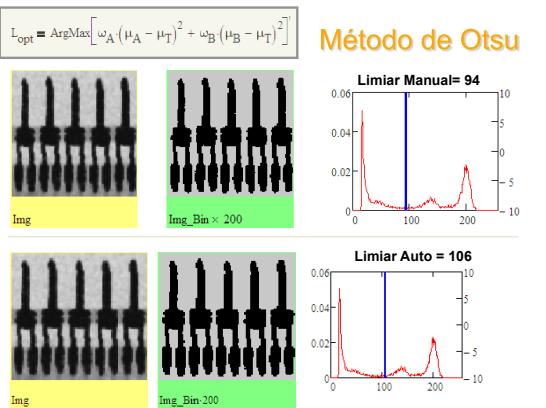


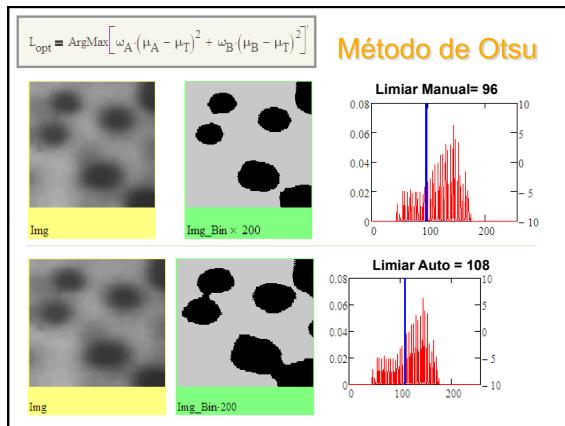
Exemplo

- Suponha o histograma
– [8,7,2,6,9,4]

0	0	1	4	4	5
0	1	3	4	3	4
1	3	4	2	1	3
4	4	3	1	0	0
5	4	2	1	0	0
5	5	4	3	1	0

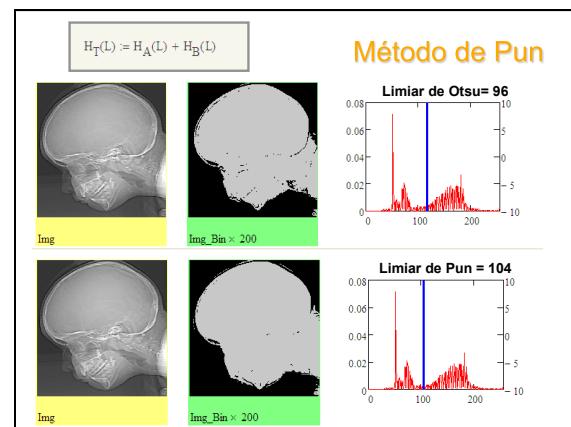
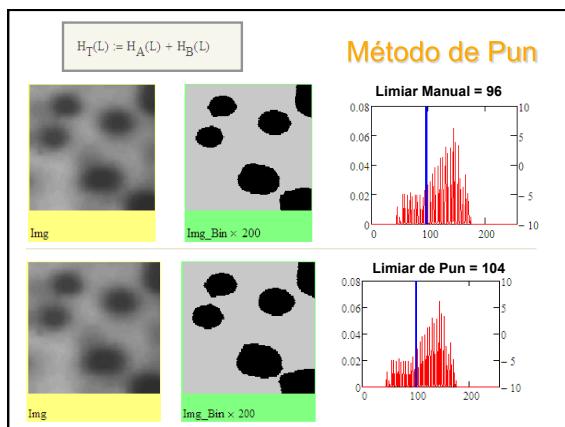
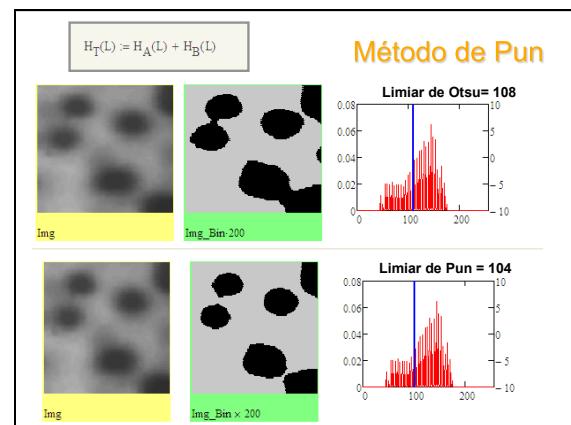
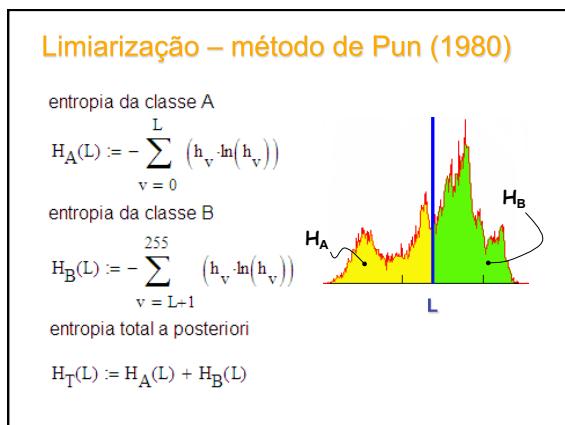
<http://www.labbookpages.co.uk/software/imgProc/otsuThreshold.html>

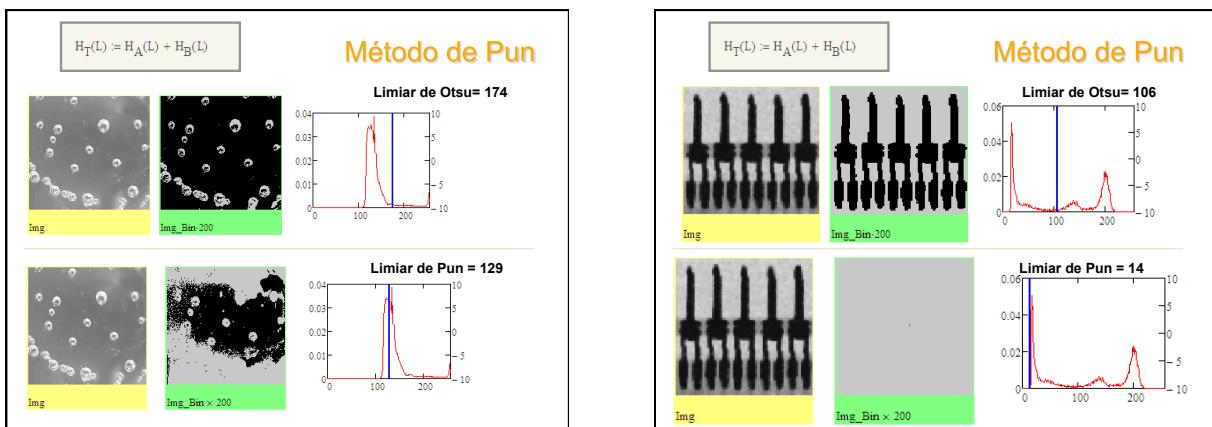
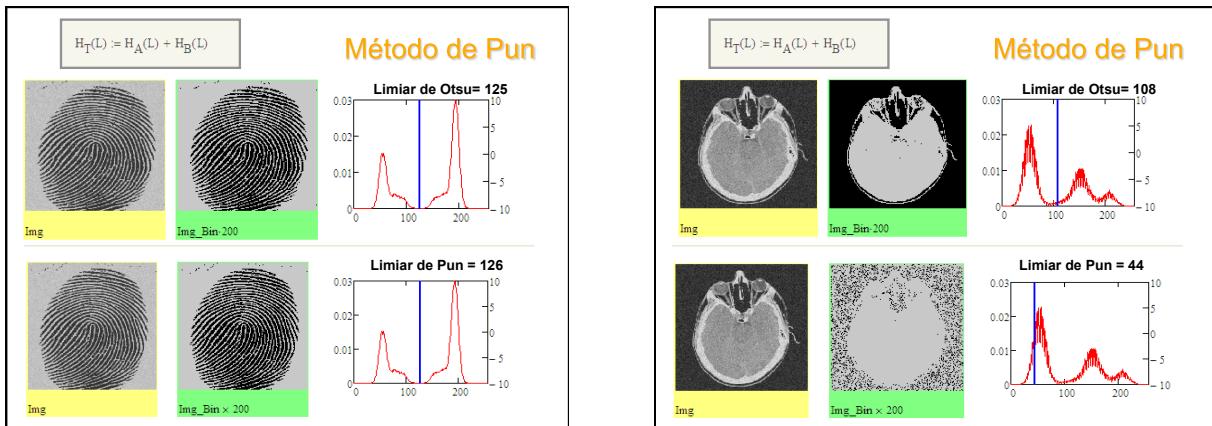




Limiarização – método de Pun(1980)

- Baseado nas entropias a posteriori
 - Calcula-se as entropias a posteriori das classes separadas com um limiar arbitrário
 - Determina-se o limiar que maximiza a entropia total a posteriori
- Exercício: (para casa)
 - Compare (em palavras) a idéia deste método com a do método de Otsu





Comparação

- O método baseado nas entropias a posteriori parece ter desempenho menor que o método baseado na variância inter-classes
- Porém ele é superior em alguns casos e empata em outros
- Os métodos de segmentação baseados em entropia estão entre os melhores. Entretanto, o método de Pun parece ser fraco
- A razão está no fato de ele não levar em consideração a correlação entre os pixels
- Como considerar isso ?
 - Requer conhecimento**
 - da estrutura topológica da imagem
 - da regularidade da imagem

Threshold adaptativo

- O método é baseado nas estatísticas locais da vizinhança de um ponto.
- Por exemplo, toma-se a média, ou a mediana locais
- Outra forma é tomar a média, ou a mediana locais, subtraídas de um certo valor.

